TráficoIA

Propuesta del equipo: predicción de tráfico, señales de tránsito y control de semáforos

Materia	Docente	Equipo
_____	_____	N.º ____

- Integrante 1: _____ (coordinación; lidera supervisado)
- Integrante 2: _____ (datos y EDA; lidera no supervisado)
- Integrante 3: _____ (simulación; lidera refuerzo)
- Integrante 4: _____ (interfaz y repositorio; lidera CNN)

1. Problema y justificación

La congestión urbana y las señales de tránsito mal interpretadas generan retrasos y accidentes. Un sistema de apoyo a la movilidad necesita responder cuatro preguntas distintas: **¿cuánto tráfico habrá?**, **¿qué tipos de día existen?**, **¿qué señal tengo enfrente?** y **¿cómo conviene operar el semáforo?**. TráficoIA es un prototipo que integra un módulo de aprendizaje automático para cada pregunta: aprendizaje supervisado, no supervisado, una red neuronal convolucional (CNN) y aprendizaje por refuerzo. Es un prototipo académico: se prioriza que funcione, que se entienda y que se explique, no la precisión de un producto profesional.

2. Objetivos

General. Construir en Python, con un entorno de Anaconda, un prototipo que integre los cuatro enfoques para apoyar la gestión del tráfico en una intersección.

- Predecir el nivel de tráfico (bajo, medio, alto) con al menos tres algoritmos supervisados comparados.
- Agrupar días por su perfil horario y proponer un horario de semáforo para cada tipo de día.
- Reconocer 12 señales de tránsito con una CNN propia entrenada en PyTorch.
- Entrenar un agente de Q-learning que reduzca la espera promedio frente a un semáforo de tiempo fijo.
- Integrar los módulos en una aplicación Streamlit demostrable y documentada.

3. Datos

Componente	Conjunto de datos	Descripción y licencia
Supervisado y no supervisado	Metro Interstate Traffic Volume (UCI, #492)	Volumen horario de tráfico en la autopista I-94 (sentido oeste, Minnesota, EE. UU.), 2012 a 2018, con clima y festivos. Licencia CC BY 4.0 (confirmar en la página del dataset antes de entregar).
CNN	GTSRB, señales alemanas (43 clases)	Más de 39 000 imágenes de entrenamiento. Se usarán 12 clases: cinco límites de velocidad (30, 50, 60, 70 y 80 km/h), ceda el paso, alto, entrada prohibida, precaución general, obras, niños y mantenga la derecha. Condiciones de uso: ver página oficial y citar a Stallkamp et al. (2012).
Refuerzo	Cruce simulado por el equipo	Entorno propio de Gymnasium; no requiere dataset.

Las 12 clases incluyen cinco límites de velocidad a propósito: son visualmente muy parecidos y permiten un análisis de errores más interesante en la matriz de confusión.

4. Hallazgos preliminares del EDA

[Completar con 3 a 4 hallazgos de 01_eda.ipynb que cambien decisiones: calidad de datos, patrón horario, efecto de festivos y clima, desbalance de imágenes. Cada hallazgo debe terminar con la decisión que se tomó.]

5. Metodología y métricas por módulo

Módulo	Tarea y método	Evaluación
Supervisado	Clasificar nivel de tráfico (terciles del volumen, calculados solo con entrenamiento) con hora, día, temperatura, lluvia y festivo. Árbol de decisión, Random Forest y KNN.	80 % entrenamiento / 20 % prueba; validación cruzada de 5 particiones. Exactitud, F1 macro y matriz de confusión.
No supervisado	Agrupar días por su perfil de 24 horas. StandardScaler, K-Means, DBSCAN y PCA para visualizar.	Método del codo, coeficiente de silueta y proporción de ruido en DBSCAN.
CNN	Clasificar 12 señales en imágenes a color de 32 × 32 o 48 × 48. Tres bloques Conv-ReLU-MaxPool, Dropout y capas densas; aumento de datos; separación por secuencia.	Exactitud, curvas de pérdida y exactitud por época, matriz de confusión y análisis de señales confundidas.
Refuerzo	Cruce de dos vías con semáforo de dos fases. Estado: colas (0 a 4) y fase. Acciones: mantener o cambiar. Recompensa: menos 1 por auto en espera y menos 1 por cambio de fase. Q-learning tabular.	Espera promedio por auto frente a semáforo de tiempo fijo; recompensa por episodio; 3 combinaciones de hiperparámetros.

6. Plan de trabajo

Entrega	Fecha	Contenido	Responsable principal
Semana 1	14 y 16 nov.	Entorno, repositorio, datos, EDA y propuesta	Integrantes 1 y 2
Semana 2	21 y 23 nov.	Modelos supervisados y no supervisado	Integrantes 1 y 2
Semana 3	28 y 30 nov.	CNN y agente de refuerzo	Integrantes 4 y 3
Semana 4	5 y 7 dic.	Prototipo, repositorio, video, informe y exposición	Todo el equipo

Todos los integrantes hacen commits cada semana y deben poder explicar cualquier parte del proyecto. Se hará un reporte semanal con el formato del Anexo B.

7. Riesgos y mitigación

- **PyTorch sin GPU:** entrenar la CNN en Google Colab y descargar el modelo (.pt); el resto corre en CPU.
- **Datos con huecos y duplicados:** limpieza documentada y reproducible en src/datos.py.
- **Validación inflada en GTSRB** (fotos casi idénticas por secuencia): separar entrenamiento y validación por secuencia.
- **Enlaces de datasets caídos:** descarga con respaldo manual y manifiesto de origen; proponer alternativa al docente.

Referencias

Hogue, J. (2019). *Metro Interstate Traffic Volume* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/492/metro+interstate+traffic+volume

Stallkamp, J., Schlipsing, M., Salmen, J., y Igel, C. (2012). Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. *Neural Networks, 32*, 323-332.

Sutton, R. S., y Barto, A. G. (2018). *Reinforcement learning: An introduction* (2.ª ed.). MIT Press.